

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
<БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ>

ФАКУЛЬТЕТ ЭЛЕКТРОННО-ИНФОРМАЦИОННЫХ СИСТЕМ

Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1

Специальность АС-67

Выполнил
В. В. Давидюк,
студент группы АС-67

Проверил
А. А. Крощенко,
ст. преп. кафедры ИИТ,
«___» _____ 2026 г.

Брест 2026

Цель работы: получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 3

Выборка Iris. Классический набор данных для классификации, содержащий измерения длины и ширины чашелистиков и лепестков для трех видов ирисов. Задачи:

1. Загрузите данные и проверьте, есть ли в них пропущенные значения.
2. Выведите количество образцов каждого вида ириса.
3. Постройте парные диаграммы рассеяния (pair plot) для всех признаков, чтобы визуально оценить их разделимость.
4. Для каждого вида ириса рассчитайте среднее значение по каждому из четырех признаков.
5. Создайте "ящик с усами" (box plot) для признака Petal Length (cm), чтобы сравнить его распределение по разным видам ирисов.
6. Стандартизируйте данные (приведите к нулевому среднему и единичному стандартному отклонению).

Выполнение:

Код программы:

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

plt.rcParams["figure.figsize"] = (10, 6)
df = pd.read_csv("iris.csv")

print("\n1. Первые 5 строк датасета")
print(df.head())
print("\n2. Информация о типах столбцов (.info())")
df.info()
print("\n3. Основные статистические показатели (.describe())")
print(df.describe().T[["mean", "50%", "std"]])
print("\n4. Проверка на пропущенные значения")
missing_values = df.isnull().sum()
print(missing_values)

if missing_values.sum() > 0:
    df = df.fillna(df.median(numeric_only=True))
    print("Пропуски обработаны.")
else:
    print("Пропуски в данных отсутствуют.")

# Количество образцов каждого вида
```

```

print("\nРаспределение по видам ирисов")
print(df["variety"].value_counts())
numeric_features = ["sepal.length", "sepal.width", "petal.length", "petal.width"]

# Парные диаграммы рассеяния с легендой
species_colors = {"Setosa": "red", "Versicolor": "green", "Virginica": "blue"}
colors = df["variety"].map(species_colors)

axes = pd.plotting.scatter_matrix(
    df[numeric_features],
    c=colors,
    figsize=(10, 10),
    diagonal="hist",
    alpha=0.8,
    s=40,
)

# Создаем элемент легенды
handles = [
    plt.Line2D(
        [0],
        [0],
        marker="o",
        color="w",
        markerfacecolor=color,
        markersize=10,
        label=species,
    )
    for species, color in species_colors.items()
]

# Добавляем легенду в верхний правый угол фигуры
plt.figlegend(
    handles=handles,
    title="Вид ириса",
    loc="upper right",
    bbox_to_anchor=(0.98, 0.98),
    fontsize=10,
    title_fontsize=11,
)

plt.suptitle("Парные диаграммы рассеяния для признаков Ириса", y=0.98, fontsize=14)
plt.subplots_adjust(top=0.93)
plt.show()

# Средние значения по каждому виду
print("\nСредние значения признаков по видам ирисов")
print(df.groupby("variety")[numeric_features].mean())

# Ящик с усами
fig, ax = plt.subplots(figsize=(8, 6))

```

```

df.boxplot(column="petal.length", by="variety", grid=True, ax=ax)
plt.title("Распределение Petal Length по видам ирисов")
plt.suptitle("")
plt.xlabel("Вид ириса")
plt.ylabel("Petal Length (см)")
plt.tight_layout()
plt.show()

# One-Hot Encoding и стандартизация
df_encoded = pd.get_dummies(df, columns=["variety"], drop_first=False, dtype=int)

df_scaled = df_encoded.copy()
df_scaled[numeric_features] = (
    df[numeric_features] - df[numeric_features].mean()
) / df[numeric_features].std()

print("\nСтатистика после ручной стандартизации (mean ≈ 0, std = 1)")
print(df_scaled[numeric_features].describe().T[["mean", "std"]])

```

Результат программы:

1. Первые 5 строк датасета

	sepal.length	sepal.width	petal.length	petal.width	variety
0	5.1	3.5	1.4	0.2	Setosa
1	4.9	3.0	1.4	0.2	Setosa
2	4.7	3.2	1.3	0.2	Setosa
3	4.6	3.1	1.5	0.2	Setosa
4	5.0	3.6	1.4	0.2	Setosa

2. Информация о типах столбцов (.info())

```

<class 'pandas.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   sepal.length  150 non-null   float64
1   sepal.width   150 non-null   float64
2   petal.length  150 non-null   float64
3   petal.width   150 non-null   float64
4   variety       150 non-null   str
dtypes: float64(4), str(1)
memory usage: 6.0 KB

```

3. Основные статистические показатели (.describe())

	mean	50%	std
sepal.length	5.843333	5.80	0.828066
sepal.width	3.057333	3.00	0.435866
petal.length	3.758000	4.35	1.765298
petal.width	1.199333	1.30	0.762238

4. Проверка на пропущенные значения

```

sepal.length  0
sepal.width    0

```

petal.length 0
petal.width 0
variety 0
dtype: int64
Пропуски в данных отсутствуют.

Распределение по видам ирисов

variety
Setosa 50
Versicolor 50
Virginica 50
Name: count, dtype: int64


Средние значения признаков по видам ирисов

	sepal.length	sepal.width	petal.length	petal.width
variety				
Setosa	5.006	3.428	1.462	0.246
Versicolor	5.936	2.770	4.260	1.326
Virginica	6.588	2.974	5.552	2.026

Статистика после ручной стандартизации (mean $\approx$ 0, std = 1)

	mean	std
sepal.length	-5.684342e-16	1.0
sepal.width	-7.815970e-16	1.0
petal.length	-2.842171e-16	1.0
petal.width	-3.789561e-16	1.0

Парные диаграммы рассеяния для признаков Ириса



Распределение Petal Length по видам ирисов

